Предсказание индекса селективности против вируса оспы

модель машинного обучения по SMILES, штамм VACV

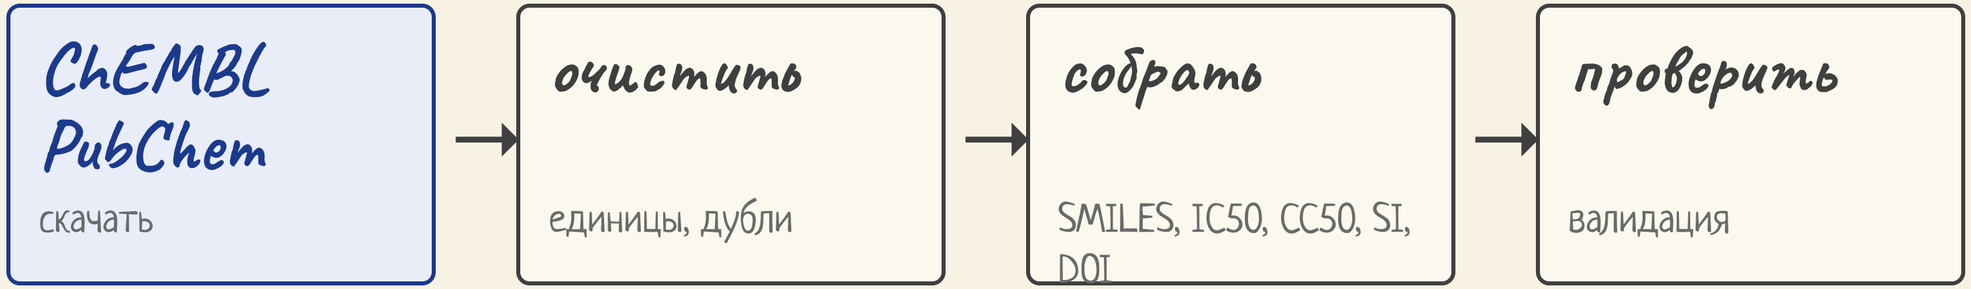
SMILES: запись молекулы строкой. SI = CC50 / IC50: во сколько раз доза, убивающая клетки, больше дозы, подавляющей вирус

СЫРНАЯ ПЛАНЕТА 4.0 | МИСИС

Nuclear IT Hack 2026

Данные

База из открытых источников: 1870 соединений, у каждого есть DOI.



0

так записано SI соединения без IC50: неактивно. Таких 81 из 320.

В первой версии файла там стояло 10000, организаторы исправили на 0.

источники: ebi.ac.uk/chembl/api/data, pubchem.ncbi.nlm.nih.gov/rest/pug. У 460 соединений оба числа измерены точно, у остальных одно из них граница вида «больше 100».

Метрику задают считанные соединения с огромным SI.



- 94% одно соединение, SI 36 067
- 4% ещё два, SI 5000
- 2% остальные 317

доля квадрата отклонения от среднего в обучающей выборке из 320 соединений

4,25 → 4,24 млн

так меняется MSE, если неактивные определены идеально

Исследование

Мы проверили 14 направлений.

- ✓ деревья по структуре молекулы
  AUC 0,85
- ✓ контекст записи: статья, культура
  AUC 0,88
- ✓ кодирование группы strain+Culture
  сильнее структуры
- ✓ смесь вероятностей, не признаков
  14,0 против 16,9 млн
- ✓ значения из таблиц статей
  главный выигрыш
- ~ блоки химических признаков
  AUC 0,925 одной химии
- ~ граф по сходству Танимото
  лучше на новых сериях
- ~ поправка по графу остатков
  ещё минус 1,3%
- ✗ нейросети, 11 подходов
  читают почерк SMILES
- ✗ мультизадачность IC50 и CC50
  вес в смеси 0,0
- ✗ TabICL и CheMeleon
  вклад около нуля
- ✗ калибровка вероятностей
  выигрыш кажущийся
- ✗ активное SI для каждой строки
  ничего не меняет
- ✗ стекинг и сосед по номеру
  не лучше фикс. весов

MSE и AUC, метки первой версии, если не сказано иное. Все опыты: приложение и папка experiments

Каждый шаг проверен: от исходной модели до общего чекпоинта минус 12%.



MSE, млн, случайные разбиения, метки первой версии; шкала от 7,5

минус 11,6% на случайных разбиениях и минус 16,9% на новых сериях

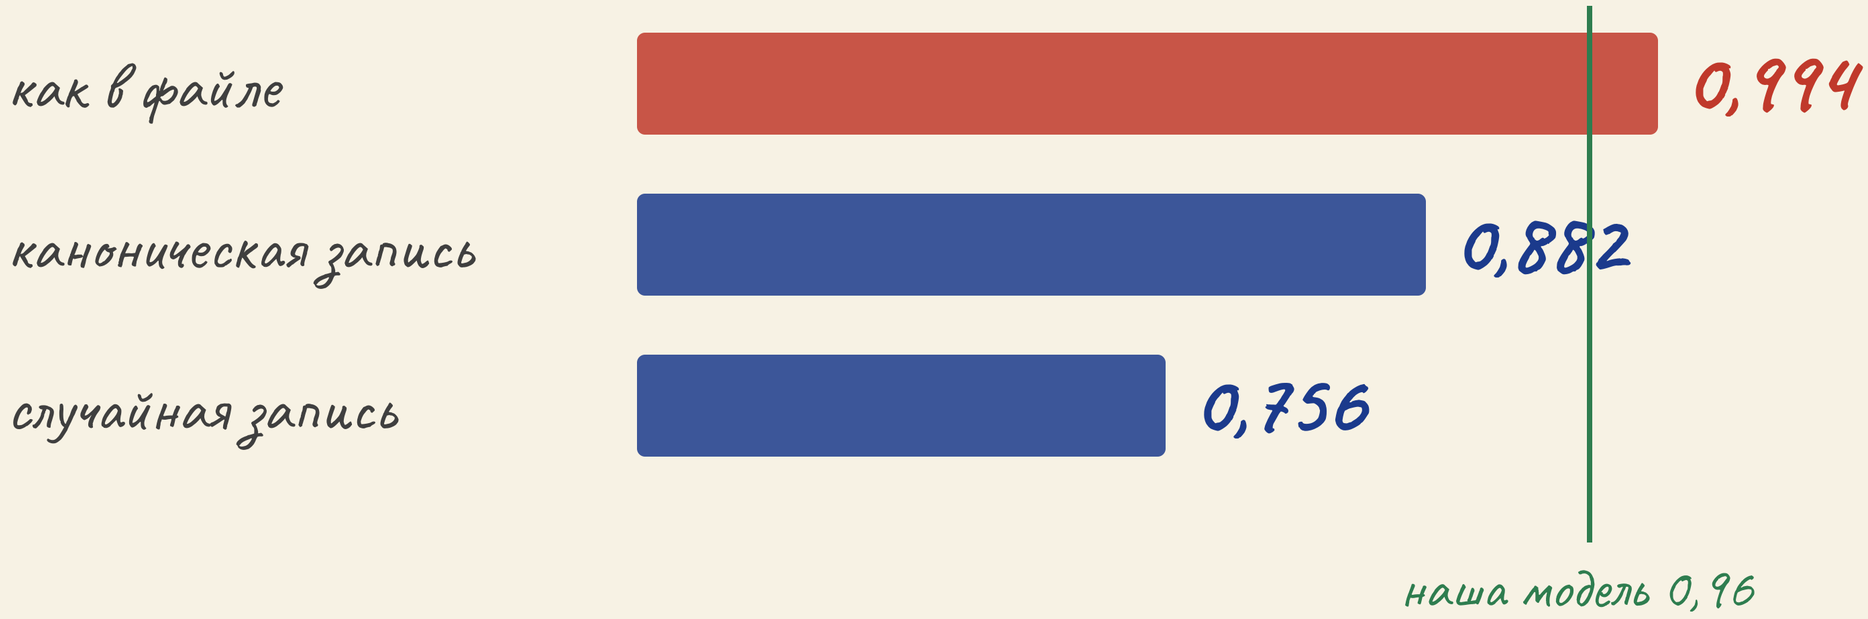
Таблицу статьи берём, только если она воспроизводит обучение бит в бит.

✓ JMC 2005, фуро/пирролопиримидиноны	обучение 11 из 11	тест +13
✓ JMC 2007, имид-гидразиды тековиримата	обучение 15 из 15	тест +18
✓ JMC 2008, скрининг	обучение 8 из 8	тест +18
✓ CBDV 2018, борнильные эфиры и амиды	обучение 15 из 15	тест +16
✓ ChemMedChem, фенхиламиды 9i–9l	обучение 28 из 28	тест +45
✓ Retro-1 и аналоги	обучение 11 из 11	тест +11
✓ ReFRAME, перепрофилированные	обучение 5 из 5	тест +15
✓ BMCL 2016, хиназолины 24a/24b	обучение 13 из 13	тест +13

якорь: строки обучения, значения которых таблица воспроизводит точно. Не прошла таблица, не берём.

ветка коллеги: честная CV 8,02 → 1,97 млн (метки первой версии), воспроизведение на main в работе

Нейросеть выигрывала только из-за записи SMILES.



ChemBERTa, AUC классификатора неактивных, шкала от 0,5. Канонизация снимает выигрыш

141 из 320 строк в файле записаны неканонично, а запись совпадает внутри статьи

Три красивых результата, которые не выдержали честной проверки.

калибровка вероятности 11,75 → 14,94

обычная проверка против вложенной, MSE млн

нейросеть на SMILES 0,994 → 0,882

как в файле против канонической записи, AUC

обратные веса источников 10,28 → 11,38

простая смесь против смеси по обратной ошибке, MSE млн

мы поймали каждую до отправки на Kaggle, потому что проверяли вложенной кросс-проверкой

Итог исследования

Итоговая модель честно лучше константы, а предел задают данные.

структура, контекст, близкие соединения → p = P(неактивно) → SI = (1 − p) · среднее активных



MSE, метки train_v2, меньше лучше

Kaggle, публичная часть: 1,71 млн

348 из 597 тестовых соединений без значения в открытых базах

Проверяемость

Запрещённые колонки не читаются, результат воспроизводится.

SMILES	strain	Culture	~~CC50_uM~~	~~IC50_uM_VACV~~

по ним SI считается точно, поэтому результат на них ничего не доказывает. 189 тестов следят, что мы их не читаем

1. *собрать базу*
   `uv run python -m vacv.cli all`
2. *проверить модель*
   `PYTHONPATH=. uv run python scripts/cv.py`
3. *получить ответ*
   `PYTHONPATH=. uv run python scripts/submit.py`

чистая установка проверена: 189 тестов и файл ответа. Аудит 7 ноября: две проблемы закрыты

Итог

Мы показали, где индекс селективности предсказуем, а где нет.

github.com/s1rne/vacv-si

СЫРНАЯ ПЛАНЕТА 4.0 | МИСИС

Симаранов Александр, @s1rne

Все опыты. MSE млн и AUC, метки первой версии (10000), сравнивать внутри строки.

оценка среднего активных: константа, логарифм, сырая шкала	разницы нет, 14,69–14,75
ExtraTrees против LightGBM, леса, SVM, логрегрессии	AUC 0,846 против 0,804–0,832
контекст записи без структуры	AUC 0,882
смесь вероятностей, а не признаков	14,04 против 16,93 и 14,16
изотоническая калибровка	11,75 обычно, 14,94 вложенно
tf-idf вместо категорий для контекста	15,21 против 13,97
химия: блоки признаков и структурный ансамбль	AUC 0,925, MSE 12,75
мультизадачность: IC50 и CC50 раздельно	вес в смеси 0,0; обратные веса 11,38 против 10,28
граф по Танимото	10,14 случайно, 11,78 остовы; hybrid 9,57 и 11,98
TabICLv2	10,82 и 15,70: хуже
CheMeleon + TabICL в чекпоинте	8,708 против 8,707: нуль
поправка по графу остатков	8,826 → 8,707
общий чекпоинт	8,635 и 11,850 против 9,766 и 14,255

Нейросети: AUC неактивных, случайное разбиение и новые остовы.

ChemBERTa, SMILES как в файле	0,994 и 0,978
MoLFormer-XL, как в файле	0,985 и 0,984
ChemBERTa, канонический SMILES	0,882 и 0,794
MoLFormer-XL, канонический SMILES	0,870 и 0,839
ChemBERTa, случайная запись	0,756 и 0,709
ChemBERTa + morgan + ExtraTrees, канон	0,915 и 0,824
AttentiveFP + RDKit	0,897 и 0,857
GIN + RDKit	0,888 и 0,854
D-MPNN + RDKit + morgan	0,880 и 0,846
ансамбль деревьев (наш)	0,960 и 0,914

источник: docs/neural.md, ветка exp/neural