Предсказание индекса селективности против вируса оспы

модель машинного обучения по SMILES, штамм VACV

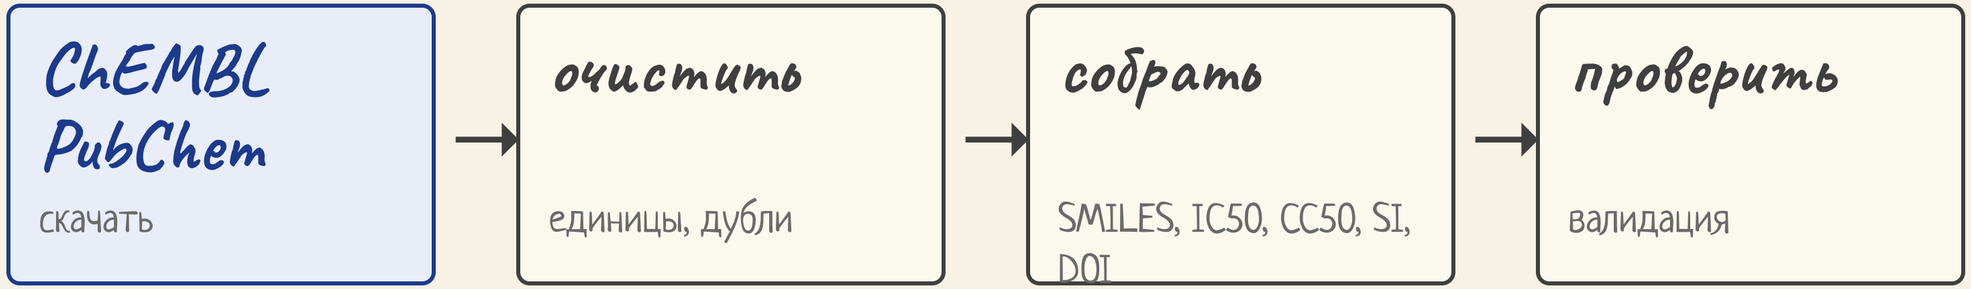
SMILES: запись молекулы строкой. SI = CC50 / IC50: во сколько раз доза, убивающая клетки, больше дозы, подавляющей вирус

СЫРНАЯ ПЛАНЕТА 4.0 | МИСИС

Nuclear IT Hack 2026

Данные

База из открытых источников: 1870 соединений, у каждого есть DOI.



0

так записано SI соединения без IC50: неактивно. Таких 81 из 320.

В первой версии файла там стояло 10000, организаторы исправили на 0.

источники: ebi.ac.uk/chembl/api/data, pubchem.ncbi.nlm.nih.gov/rest/pug. У 460 соединений оба числа измерены точно, у остальных одно из них граница вида «больше 100».

Метрику задают считанные соединения с огромным SI.



- 94% одно соединение, SI 36 067
- 4% ещё два, SI 5000
- 2% остальные 317

доля квадрата отклонения от среднего в обучающей выборке из 320 соединений

4,25 → 4,24 млн

так меняется MSE, если неактивные определены идеально

Путь к результату

Три отправки на Kaggle, и каждая объяснила следующий шаг.

гибрид, метка 10000



18,15 млн

организаторы поменяли метку

регрессия, метка 0



2,04 млн

ET-log по SI

pair-delta v4



1,71 млн

разности между близкими структурами

Kaggle, публичная часть, MSE. Метка у неактивных: 10000 до train_v2, 0 после

Исследование

14 направлений, в итог вошло одно.

✓ разности между близкими структурами
Ridge-log, v4: итог

✓ регрессия по log SI на train_v2
4,24 млн на CV, Public 2,04

~ ядро контекст на структуру
4,23 против 4,01 у пар

~ внешние пары записей
3,69 против 3,60 у v4

✗ эксперт по одному разрезу MMP
покрыл 13–16 строк

✗ нелинейное парное ядро
4,12 против 3,60

✗ бэггинг пар, радиус 2+3, ансамбль
хуже v4 на общих разбиениях

✗ ExtraTrees, CatBoost, Kernel Ridge
ансамбль хуже на 12,1%

✗ калибровка и хиральность
хуже, 4,21 и 4,26 против 3,84

✗ CheMeleon и TabICL
выигрыша нет

✗ нейросети на SMILES, 11 подходов
читают почерк записи

✗ экстраполяция хвоста sqrt-Ridge
MSE 10^16, провал

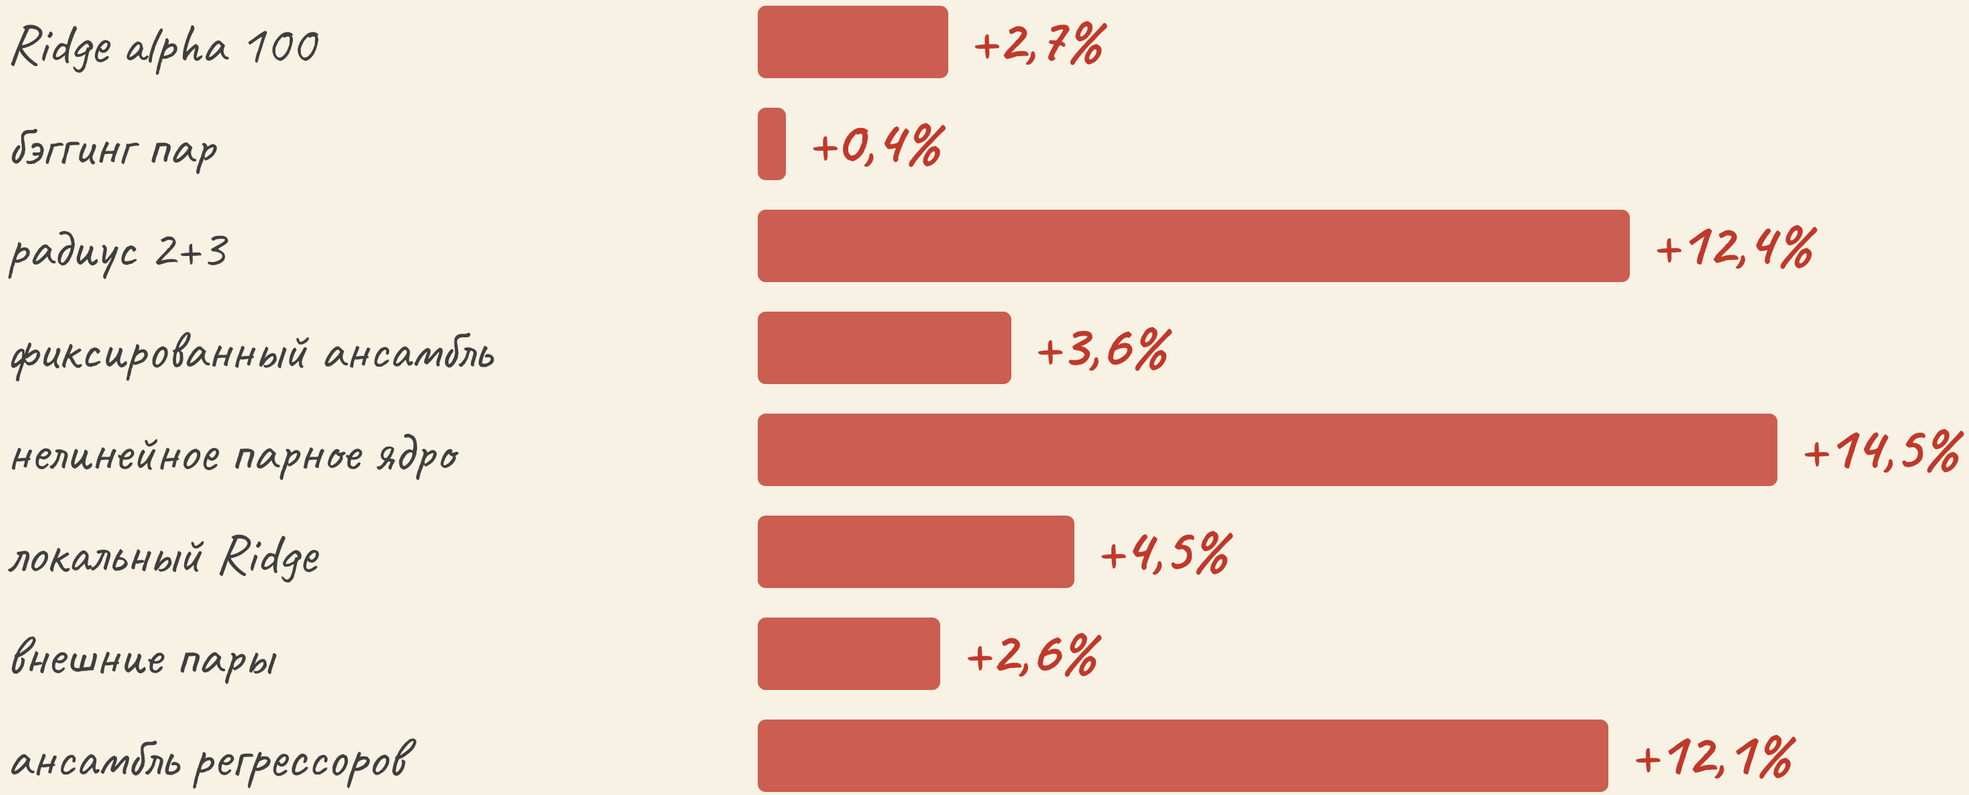
✗ граф по сходству Танимото
до смены метки, выигрыша нет

~ таблицы статей и восстановление базы
отдельная ветка, в итог не вошла

Все запуски: 54 каталога в experiments/results, каталог в docs/experiment-inventory.json

Претенденты

Восемь претендентов на замену v4. Ни один не победил.



насколько хуже v4 по MSE на тех же разбиениях. Ноль означает ничью, победителей нет

Нейросеть выигрывала только из-за записи SMILES.



ChemBERTa, AUC классификатора неактивных, шкала от 0,5. Канонизация снимает выигрыш

141 из 320 строк в файле записаны неканонично, а запись совпадает внутри статьи

Три красивых результата, которые не выдержали честной проверки.

калибровка 3,84 → 4,21

вложенная калибровка, MSE млн, три схемы

ансамбль регрессоров 3,84 → 4,31

выбранный на внутренних фолдах против v4, MSE млн

нейросеть на SMILES 0,994 → 0,882

как в файле против канонической записи, AUC

мы ловили такое вложенной проверкой до отправки на Kaggle

Итоговая модель

v4: достраиваем ответ от трёх близких молекул с известным SI.

молекула без ответа, strain и Culture → до 3 опор в том же контексте, сходство от 0,7 → log SI опор + Δ

Ridge обучен на разностях log1p(SI) пар близких структур, Morgan 2048 бит

1,71 млн

Kaggle, публичная часть, MSE

минус 16,09% к прошлому результату 2,04 млн

локальная проверка 3,84 млн против 4,25 у константы. Публичная часть и проверка считаются на разных строках

Проверяемость

Запрещённые колонки не читаются, результат совпал до байта.

SMILES	strain	Culture	~~CC50_uM~~	~~IC50_uM_VACV~~

по ним SI считается точно, поэтому результат на них ничего не доказывает

1 *загрузить файлы*

```
python scripts/import_competition_v2.py <zip Kaggle>
```

2 *воспроизвести отправку*

```
PYTHONPATH=. python scripts/reproduce_final.py
```

3 *проверить*

```
uv run pytest
```

файл ответа совпал с отправленным побайтно, SHA-256 одинаков. Проверок: 396

Итог

Мы показали, где индекс селективности предсказуем, а где нет.

github.com/s1rne/vacv-si

СЫРНАЯ ПЛАНЕТА 4.0 | МИСИС

Симаранов Александр, @s1rne

Хронология результатов. MSE млн, сравнивать внутри строки.

гибрид с меткой 10000	CV 8,8–9,0; Kaggle 18,15
те же модели на метках train_v2	22,87–25,07: не та задача
v2: регрессия ET-log	CV 4,241 и 4,263 по остовам; Kaggle 2,04
v3: power-преобразование и sqrt-Ridge	4,249 против 4,268; провал 10^16
v4: pair-delta Ridge-log	6 разбиений 3,511 против 4,004; Kaggle 1,71
v5: alpha 100, бэггинг, радиус 2+3, ансамбль	3,781; 3,696; 4,136; 3,812 против 3,681
v6: парное ядро, локальный, внешние пары	4,117; 3,755; 3,690 против 3,595
v8 и v9: вложенный отбор и бэкенды	v4 3,844; ансамбль 4,309
v10: калибровка и хиральность	4,209; 4,263; 4,270

Нейросети: AUC неактивных, случайное разбиение и новые остовы.

ChemBERTa, SMILES как в файле	0,994 и 0,978
MoLFormer-XL, как в файле	0,985 и 0,984
ChemBERTa, канонический SMILES	0,882 и 0,794
MoLFormer-XL, канонический SMILES	0,870 и 0,839
ChemBERTa, случайная запись	0,756 и 0,709
ChemBERTa + morgan + ExtraTrees, канон	0,915 и 0,824
AttentiveFP + RDKit	0,897 и 0,857
GIN + RDKit	0,888 и 0,854
D-MPNN + RDKit + morgan	0,880 и 0,846
ансамбль деревьев (наш)	0,960 и 0,914

источник: docs/neural.md, ветка exp/neural